0.1 Название:

0.2 Авторы

- Самаркин А.И.
- Самаркина Е.И.
- Ревенко А.Б.
- Щеткина
- Иванова Н.В.
- Белов В.С.

0.3 1. Введение

0.3.1 1.1 Научный контекст

Пандемия COVID-19, официально зафиксированная Всемирной организацией здравоохранения в марте 2020 года, потребовала от систем общественного здравоохранения принципиально новых инструментов количественного анализа эпидемического процесса. Математическое моделирование инфекционных заболеваний, берущее начало в работах Кермака и Маккендрика [1], к этому моменту располагало устоявшейся методологической базой: компартментные модели типа SIR, SEIR и их расширения широко применялись для описания динамики гриппа, кори, лихорадки Эбола и ряда других инфекций. Тем не менее опыт пандемии COVID-19 обнажил существенные ограничения этого аппарата при работе с реальными данными рутинного надзора.

Главная **практическая проблема** состоит в следующем: данные государственной эпидемиологической отчётности накапливаются в разнородных форматах, содержат систематические пропуски и не предназначены для непосредственного использования в динамических моделях. Между тем именно эти данные — доступные в любом учреждении санитарно-эпидемиологического надзора — представляют наибольший практический интерес: специализированные регистры и системы геномного надзора существуют лишь в крупных административных центрах и охватывают незначительную долю случаев. Для малых и средних городов России (с численностью населения от 50 до 500 тысяч человек) задача ретроспективного количественного анализа пандемии на основе стандартной отчётности остаётся актуальной.

Помимо проблемы качества данных, пандемия COVID-19 поставила перед математическим моделированием **новый содержательный вызов**. Последовательная смена доминирующих вариантов SARS-CoV-2 — от исходного уханьского штамма через Альфа и Дельта к многочисленным субвариантам Омикрон — сопровождалась не только изменением биологических параметров возбудителя (базового репродуктивного числа R_0, длительности инкубационного и инфекционного периодов, летальности), но и принципиальным изменением иммунологического контекста: к середине 2022 года значительная часть популяции обладала гибридным иммунитетом, сформировавшимся в результате перенесённой инфекции и/или вакцинации [2], а также изменившемся социальным поведением, которое меняет параметры распространения вируса, и, в свою очередь, существенно меняет динамику волн: в частично иммунной популяции рост заболеваемости замедляется

не только вследствие истощения восприимчивых, но и под влиянием сложных эффектов иммунологической памяти, действующих на различных временных масштабах.

Стандартные компартментные модели с производными целого порядка не располагают механизмом для описания такой «памяти» системы: текущее состояние определяется исключительно мгновенными значениями переменных, а не историей их изменения. Дробное исчисление, и в частности производная Капуто порядка $\alpha \in (0, 1]$, предоставляет математически строгий инструмент для включения наследственных эффектов в динамические модели [3]. В уравнении с производной Капуто правая часть интегрирует взвешенную историю состояния системы с убывающим степенным ядром памяти: при $\alpha \to 1$ модель вырождается в стандартную систему ОДУ, при $\alpha < 1$ — **описывает субдиффузионный режим**, при котором изменения происходят медленнее, чем предсказывает экспоненциальная кинетика. Применительно к эпидемиологии это соответствует ситуации, когда **восприимчивость популяции к инфекции в данный момент определяется не только текущим числом восприимчивых особей, но и накопленным иммунным опытом предшествующих волн**.

Таким образом, **задача разработки методологии ретроспективного анализа COVID-19 на уровне отдельного города**, опирающейся на данные рутинного надзора и сочетающей покоординатную привязку параметров к доминирующим вариантам вируса с дробным расширением компартментной модели, **представляется как научно актуальной, так и практически значимой**.

Список литературы (к разделу 1.1)

1. Kermack W. O., McKendrick A. G. A contribution to the mathematical theory of epidemics // Proceedings of the Royal Society A. — 1927. — Vol. 115, № 772. — P. 700–721. — DOI: 10.1098/rspa.1927.0118.

2. Xu X., Wu Y., Kummer A. G. [et al.] Assessing changes in incubation period, serial interval, and generation time of SARS-CoV-2 variants of concern: a systematic review and meta-analysis // BMC Medicine. —

3. — Vol. 21, № 1. — Art. 374. — DOI: 10.1186/s12916-023-03070-8.

3. Diethelm K. The Analysis of Fractional Differential Equations: An Application-Oriented Exposition Using Differential Operators of Caputo Type. — Berlin : Springer, 2010. — 247 p. — DOI: 10.1007/978-3-642-14574-2.

0.3.2 1.2 Обзор литературы

1.2.1 Классическая теория компартментных моделей Математическое моделирование инфекционных заболеваний опирается на **основополагающую работу Кермака и Маккендрика [1], в которой была предложена компартментная SIR-модель**, описывающая динамику эпидемии через систему нелинейных ОДУ с тремя состояниями: восприимчивые (S), инфекционные (I) и выздоровевшие (R). Несмотря на очевидную упрощённость, эта работа заложила формальный фундамент количественной эпидемиологии и ввела понятие базового репродуктивного числа R_0 — порога, определяющего возможность эпидемического распространения. Принципиальное достоинство подхода состоит в

аналитической прозрачности: условие возникновения эпидемии $R_0 > 1$ выводится строго из структуры модели. Ограничением является гомогенное перемешивание популяции и постоянство параметров передачи, **что делает SIR-модель адекватной лишь для описания изолированной вспышки при постоянных условиях среды**.

Монументальный вклад в теорию инфекционных болезней внесла **монография Андерсона и Мэя [2], систематизировавшая компартментные модели** применительно к широкому кругу инфекций. Авторы показали, что введение инкубационного периода (компартмент E) существенно улучшает описание эпидемической кривой для инфекций с длительной преинфекционной фазой, к числу которых относится и COVID-19. Модель SEIR и её расширения — включая вариант с явным учётом летальных исходов (SEIRD) — стали стандартом в эпидемиологическом моделировании [2]. Тем не менее **критическим недостатком всей этой группы моделей остаётся их «безпамятный» (иначе говоря марковский) характер**: правая часть системы ОДУ в любой момент времени определяется исключительно текущими значениями переменных состояния, тогда как в реальной эпидемической динамике нарастание иммунитета, изменение поведения популяции и смена вариантов возбудителя создают выраженную зависимость от истории процесса.

Проблема идентифицируемости SEIRD-модели (точнее ее параметров) при работе с реальными данными детально проанализирована в работе Королёва [3]. Автор демонстрирует, что множество векторов параметров обеспечивают практически одинаковое краткосрочное описание наблюдаемых рядов заболеваемости и смертности, однако дают радикально различные долгосрочные прогнозы — принципиально важное обстоятельство для задач, решаемых в настоящей работе. Дополнительно показывается, что **неучёт занижения регистрируемых случаев приводит к систематическому смещению оценки R_0 вниз**. Эти результаты напрямую обусловили выбор стратегии калибровки в настоящем исследовании: фиксацию биологических параметров (σ, γ) из литературных данных по штаммам с последующей совместной оптимизацией β, μ и начальных условий.

1.2.2 Биологические параметры вариантов SARS-CoV-2 **Смена доминирующих вариантов SARS-CoV-2 сопровождалась закономерным изменением ключевых эпидемиологических параметров**, задокументированным в многочисленных когортных и генеалогических исследованиях. Xu et al. [4] провели систематический обзор и метаанализ 147 исследований (280 записей) по инкубационному периоду, серийному интервалу и времени генерации для предкового варианта Wuhan, Alpha, Delta и Omicron. Ключевой вывод: каждый новый вариант демонстрирует прогрессивное укорочение этих параметров — с ~5–6 дней для уханьского штамма до ~2–3 дней для Omicron. Недостатком этого систематического обзора является то, что он не охватывает субварианты Omicron BA.4/5, XBB и поздние линии JN.1, данные по которым появлялись в литературе позже. Для этих субвариантов авторы прибегают к экстраполяции, что вносит неопределённость в соответствующие оценки σ и γ.

Madewell et al. [5] выполнили более специализированный метаанализ серийных интервалов именно для Delta и Omicron, включив 46 648 первично-вторичных пар для Delta и 18 324 для Omicron. Этот источник существенно точнее для задачи калибровки модели, поскольку оценки получены на однородных когортах конкретных вариантов. **Авторы указывают на среднее значение серийного интервала 2,3–5,8 дней для Delta и 2,1–4,8 дней для Omicron**, что согласуется с данными, использованными в настоящей работе для инициализации параметра γ.

1.2.3 Дробное исчисление производных: математический аппарат Дробные производные и интегралы произвольного вещественного порядка восходят к переписке Лейбница и Лопиталя в 1695 году, однако систематическое математическое развитие этот аппарат получил лишь в XIX веке. Монография Подлубного [6] — стандартный современный справочник по теории, охватывающий определения Римана–Лиувилля, Грюнвальда–Летникова и Капуто, теоремы существования и единственности, аналитические и численные методы. Для целей настоящей работы особую ценность представляет детальное сопоставление различных определений дробной производной. В отличие от производной Римана–Лиувилля, **производная Капуто допускает задание начальных условий в классической форме (значения функции и её целочисленных производных)**, что делает её предпочтительной при постановке задач Коши для динамических систем.

Монография Дитхельма [7] представляет собой специализированный прикладной трактат, полностью сосредоточенный на производных Капуто. Автор строго доказывает существование, единственность и непрерывную зависимость от начальных данных для широкого класса задач Коши с дробной производной, обсуждает устойчивость равновесных состояний дробных систем и даёт исчерпывающий анализ поведения решений в окрестности начального момента — в частности, показывает, что при $\alpha < 1$ решение развивается медленнее любой экспоненты, что соответствует субдиффузионному режиму. Эта монография является непосредственным методическим основанием для обоснования дробной SEIRD-модели, используемой в настоящей работе.

Расширенный взгляд на численные методы для дробных ОДУ представлен в монографии Балеану, Дитхельма, Скаласа и Трухильо [8]. Авторы дают сравнительный анализ методов конечных разностей, квадратурных методов и метода предиктора-корректора, указывая на их точность и вычислительную сложность. В частности, обоснован метод Грюнвальда–Летникова как явная схема первого порядка точности с ядром памяти, допускающим точное рекуррентное вычисление. Это свойство является вычислительно привлекательным при многократном решении ODE в ходе оптимизации, что делает схему GL обоснованным выбором для настоящей работы, несмотря на более низкий порядок по сравнению с методом Адамса–Башфорта–Мултона.

1.2.4 Схема предиктора-корректора для дробных ОДУ Стандартным численным методом для дробных ОДУ в форме Капуто является метод Адамса–Башфорта–Мултона (ABM), разработанный Дитхельмом, Фордом и Фридом [9]. Схема обобщает классический предиктор-корректор первого порядка на случай $\alpha \in (0, 1]$: предиктор вычисляет приближение y^P_{n+1} явно (аналог Адамса–Башфорта), корректор уточняет его одной неявной итерацией (аналог Адамса–Мултона). Авторы доказывают сходимость порядка $O(h^p)$ при $p = \min(2, 1 + \alpha)$, то есть всегда не ниже первого порядка и асимптотически второго при $\alpha \to 1$. Для задач эпидемиологического моделирования с шагом $h = 1$ день разница в точности между GL и ABM носит умеренный характер; тем не менее ABM является предпочтительным методом при $\alpha < 0.7$ или при необходимости строгого контроля погрешности. В настоящей работе ABM не использовался из соображений вычислительной простоты при оптимизации, однако рассматривается как направление совершенствования метода.

1.2.5 Дробные компартментные модели COVID-19 Rajagopal et al. [10] предложили дробную SEIRD-модель COVID-19 с производной Капуто и откалибровали её на данных ВОЗ по Италии (24 февраля — 7 апреля 2020 года). Сравнение со стандартной целочисленной моделью показало меньшую RMSE у дробной версии; предсказательная проверка на данных 8 апреля — 16 мая подтвердила преимущество. Это исследование — наиболее близкий аналог настоящей работы по структуре модели. Его принципиальным ограничением является использование данных только первой волны COVID-19 (исходный вариант Wuhan), тогда как настоящая работа охватывает 10 волн с 2020 по 2025 год при последовательной смене доминирующих вариантов. Кроме того, авторы не рассматривают вопрос о физической интерпретации подобранного значения α и не связывают его с иммунологическим контекстом конкретных волн.

Naik et al. [11] применили дробную модель с несколькими операторами (Капуто, Атангана–Балеану–Капуто) к данным COVID-19 Пакистана, включив в структуру компартмент лечения. Авторы демонстрируют, что оператор Атангана–Балеану даёт лучшее согласие с реальными данными, чем классический Капуто. Методологически важен вывод о существенном влиянии выбора оператора дифференцирования на качество подгонки, что указывает на необходимость сравнительного тестирования при калибровке дробных моделей. Недостатком данной работы является отсутствие формальных критериев выбора модели (AIC/BIC) и статистической проверки значимости $\alpha < 1$.

1.2.6 Инструментарий вычислительного моделирования Численное решение систем ОДУ в настоящей работе осуществляется с использованием пакета DifferentialEquations.jl для языка Julia [12]. Rackauckas и Nie описывают экосистему, обеспечивающую единый интерфейс к широкому спектру методов — от явных методов Рунге–Кутты (Tsit5, Vern7) до неявных решателей Розенброка (Rodas5P) — с автоматическим переключением между жёсткими и нежёсткими режимами (AutoVern7/Rodas5P). Это свойство критически важно для настоящей работы, поскольку в ходе многостартовой оптимизации параметров оптимизатор периодически пробует конфигурации с большим β или малым γ, приводящие к жёстким системам, которые разрушают явные решатели типа Tsit5. Применение автопереключающегося решателя позволяет полностью исключить ложные отказы интегратора при сохранении вычислительной эффективности на нежёстких участках траектории.

Весь аналитический конвейер настоящей работы — от обработки данных до численной оптимизации параметров — реализован на языке Julia [14]. Julia представляет собой высокоуровневый динамический язык для научных вычислений, архитектурно решающий так называемую «проблему двух языков»: традиционная практика прототипирования на Python или MATLAB с последующим переписыванием критических секций кода на C или Fortran устранена благодаря компиляции Just-in-Time через LLVM и механизму множественной диспетчеризации. Для задач настоящего исследования это обстоятельство принципиально: многостартовая оптимизация параметров SEIRD-модели требует сотен тысяч вызовов численного интегратора; реализация на чистом Julia достигает производительности, сопоставимой с Fortran, без использования внешних расширений. Дополнительным достоинством является нативная поддержка Unicode в именах переменных и функций, что позволяет непосредственно воспроизводить математические обозначения в коде (β, σ, γ, μ, α_k и т.д.) — существенно улучшая читаемость и снижая вероятность ошибок при переносе формул из публикации в программу. Устойчивое управление пакетами и воспроизводимость вычислительной среды обеспечиваются встроенным менеджером пакетов Pkg с фиксацией версий зависимостей в файле Manifest.toml.

0.3.3 Список литературы (к разделам 1.1–1.2)

1. Kermack W. O., McKendrick A. G. A contribution to the mathematical theory of epidemics // Proceedings of the Royal Society A. — 1927. — Vol. 115, № 772. — P. 700–721. — DOI: https://doi.org/10.1098/rspa.1927.011810.1098/rspa.1927.0118.

2. Anderson R. M., May R. M. Infectious Diseases of Humans: Dynamics and Control. — Oxford : Oxford University Press, 1991. — 757 p. — ISBN: 978-0-19-854040-3.

3. Korolev I. Identification and estimation of the SEIRD epidemic model for COVID-19 // Journal of Econometrics. — 2021. — Vol. 220, № 1. — P. 63–85. — DOI: https://doi.org/10.1016/j.jecono

4. Xu X., Wu Y., Kummer A. G. [et al.] Assessing changes in incubation period, serial interval, and generation time of SARS-CoV-2 variants of concern: a systematic review and meta-analysis // BMC Medicine. —

5. — Vol. 21, № 1. — Art. 374. — DOI: https://doi.org/10.1186/s12916-023-03070-810.1186/s12916-023-03070-8.

5. Madewell Z. J., Yang Y., Longini I. M. Jr. [et al.] Rapid review and meta-analysis of serial intervals for SARS-CoV-2 Delta and Omicron variants // BMC Infectious Diseases. — 2023. — Vol. 23, № 1. — Art. 429. — DOI: https://doi.org/10.1186/s12879-023-08407-510.1186/s12879-023-08407-5.

6. Podlubny I. Fractional Differential Equations: An Introduction to Fractional Derivatives, Fractional Differential Equations, to Methods of Their Solution and Some of Their Applications. — San Diego : Academic Press, 1999. — 340 p. — (Mathematics in Science and Engineering ; vol. 198). — ISBN: 978-0-12-558840-9. — DOI: https://doi.org/10.1016/s0076-5392(99)x8001-510.1016/s0076-5392(99)x8001-5.

7. Diethelm K. The Analysis of Fractional Differential Equations: An Application-Oriented Exposition Using Differential Operators of Caputo Type. — Berlin : Springer, 2010. — 247 p. — (Lecture Notes in Mathematics ; vol. 2004). — DOI: https://doi.org/10.1007/978-3-642-14574-210.1007/978-3-642-14574-2.

8. Baleanu D., Diethelm K., Scalas E., Trujillo J. J. Fractional Calculus: Models and Numerical Methods. — Singapore : World Scientific, 2012. — 400 p. — (Series on Complexity, Nonlinearity and Chaos ; vol. 3). — DOI: https://doi.org/10.1142/1004410.1142/10044.

9. Diethelm K., Ford N. J., Freed A. D. A predictor-corrector approach for the numerical solution of fractional differential equations // Nonlinear Dynamics. — 2002. — Vol. 29, № 1–4. — P. 3–22. — DOI: https://doi.org/10.1023/A:101659221934110.1023/A:1016592219341.

10. Rajagopal K., Hasanzadeh N., Parastesh F. [et al.] A fractional-order model for the novel coronavirus (COVID-19) outbreak // Nonlinear Dynamics. — 2020. — Vol. 101, № 1. — P. 711–718. — DOI: https://doi.org/10.1007/s11071-020-05757-610.1007/s11071-020-05757-6.

11. Naik P. A., Yavuz M., Qureshi S. [et al.] Modeling and analysis of COVID-19 epidemics with treatment in fractional derivatives using real data from Pakistan // European Physical Journal Plus. — 2020. — Vol. 135, № 10. — Art. 795. — DOI: https://doi.org/10.1140/epjp/s13360-020-00819-510.1140/epjp/s13360-020-00819-5.

12. Rackauckas C., Nie Q. DifferentialEquations.jl — a performant and feature-rich ecosystem for solving differential equations in Julia // Journal of Open Research Software. — 2017. — Vol. 5, № 1. — Art. 15. — DOI: https://doi.org/10.5334/jors.15110.5334/jors.151.

13. Bezanson J., Edelman A., Karpinski S., Shah V. B. Julia: a fresh approach to numerical computing // SIAM Review. — 2017. — Vol. 59, № 1. — P. 65–98. — DOI: https://doi.org/10.1137/14100

0.3.4 1.3 Пробелы в имеющихся исследованиях

1.3.1 Дефицит субнационального масштаба Подавляющее большинство публикаций по математическому моделированию COVID-19 оперирует данными национального или регионального уровня: анализируются страны, штаты, провинции [3, 10, 11]. Это обусловлено объективными причинами — доступностью агрегированных данных, — однако порождает принципиальный аналитический пробел. Как показывает обзор Гайторп и соавт. [14], **субнациональный-масштаб является приоритетным для систем эпидемиологического надзора**, поскольку именно на уровне конкретных населённых пунктов принимаются управленческие решения о медицинских ресурсах, введении ограничительных мер и их отмене. Между тем **динамика инфекции в малом городе качественно отличается от динамики в крупном административном центре**: меньший размер восприимчивой популяции ускоряет исчерпание иммунной прослойки, эффект «суперраспространителей» статистически значимее, а сезонные миграционные потоки непропорционально сильнее влияют на форму эпидемической кривой. В российских источниках **тема моделирования COVID-19 на уровне отдельного российского города** с населением менее 300 000 человек по данным рутинной отчётности **практически не освещена**.

Немногочисленные исследования, работающие на субрегиональном уровне, как правило, либо используют специализированные регистры (данные PCR-тестирования с геопривязкой, данные госпитализаций), недоступные за пределами крупных академических центров [14], либо ограничиваются пространственно-описательным анализом без калибровки компартментных моделей [15]. **Исследований, в которых компартментная модель была бы откалиброванa по данным стандартных форм государственной отчётности (аналог российских форм ВП и еженедельных сводок COVID-19) для отдельного малого города, авторам настоящей работы обнаружить не удалось.**

1.3.2 Разрыв между биологическими параметрами штаммов

и калибровкой волн Накопленная литература по биологическим параметрам вариантов SARS-CoV-2 [4, 5] представляет собой глобальные сводные оценки σ, γ, R_0 и IFR, полученные на крупных международных когортах. При этом в работах по математическому моделированию COVID-19 эти параметры, как правило, либо **заимствуются как фиксированные константы без адаптации к конкретной волне** [10], либо подбираются целиком из данных, **игнорируя биологический приоритет свойств конкретного штамма** [3].

Промежуточная стратегия — использование параметров штамма как информированного априорного распределения с последующим ограниченным числом свободных параметров подгонки — реализована в единичных работах и, как правило, без формальной проверки, насколько реальные данные отличаются от биологического prior (то есть без отчётности о $\Delta\beta$ и ΔR_0 между prior и fit).

Кроме того, **ни одна известная нам работа не проводит систематического анализа по всем волнам одного и того же наблюдаемого ряда с явной привязкой каждой волны к конкретному доминирующему варианту** и последующим сравнением подобранных параметров с биологическими оценками этого варианта. Именно этот «пооолновой» подход является ядром настоящего исследования.

1.3.3 Дробные модели: формальная селекция

и биологическая интерпретация α_k Дробные SEIRD-модели COVID-19, как показано в обзоре выше [10, 11, 16], демонстрируют эмпирически лучшую подгонку к данным по сравнению с целочисленными аналогами. Тем не менее в этой группе работ **обнаруживаются три системных недостатка**.

Первый — методологический: большинство работ сравнивает модели визуально (кривые подгонки) или по одному скалярному показателю (RMSE или R^2), не применяя формальных критериев выбора модели — AIC, BIC, Likelihood Ratio Test — которые учитывают разное число параметров у целочисленной и дробной версий. Работа Ли и соавт. [16] является исключением: авторы систематически применяют AICc и BIC к пяти компартментным структурам в целочисленном и дробном вариантах на данных четырёх китайских провинций, показывая последовательное превосходство дробных моделей. Однако авторы ограничиваются первой волной COVID-19 (начало 2020 года) и не рассматривают, как оптимальный порядок α варьируется между волнами при смене вариантов вируса.

Второй недостаток — отсутствие содержательной интерпретации подобранного значения α_k. В большинстве работ α трактуется как технический параметр сглаживания или как «степень памяти системы» в абстрактном смысле. Связь α_k с конкретными популяционными процессами — нарастанием иммунитета, изменением возрастной структуры контактов, накоплением гибридного иммунитета — не формализована и не верифицирована на реальных данных через сравнение волн с известным иммунологическим контекстом.

Третий недостаток — однородность временного горизонта: практически все работы анализируют одну волну или один непрерывный ряд (нередко 2–4 месяца), что не позволяет сравнить, является ли $\alpha < 1$ специфическим для конкретных волн или представляет собой устойчивое свойство всей эпидемической кривой. Настоящая работа ликвидирует этот пробел, анализируя десять последовательных волн на одном и том же городе с применением формальных критериев выбора модели к каждой волне.

1.3.4 Воспроизводимые конвейеры для рутинных данных Существующие работы по калибровке компартментных моделей, как правило, не публикуют воспроизводимого конвейера предобработки данных, пригодного для применения к другим источникам

без значительной ручной адаптации. Данные обычно либо предоставлены специальными регистрами с унифицированным форматом [14], **либо взяты из агрегаторов типа OurWorldInData или Johns Hopkins CSSE, которые к моменту написания ряда работ уже прекратили обновление**. Задача создания воспроизводимого аналитического конвейера для работы с разнородными файлами государственной эпидемиологической отчётности — с характерными для неё слитыми заголовками Excel, пропусками и сменой форматов по годам — **остаётся нерешённой для большинства практических приложений** в контексте регионального надзора в России.

1.3.5 Итог: формулировка исследовательского зазора Таким образом, в совокупности литература демонстрирует следующие лакуны, которые заполняет настоящее исследование.

Во-первых, ретроспективный анализ всего пятилетнего периода пандемии (2020–2025) на уровне одного российского города (Псков, ~200 000 жителей) по данным исключительно рутинного санитарно-эпидемиологического надзора — без специализированных регистров и геномного секвенирования.

Во-вторых, покоординатная привязка параметров σ и γ к доминирующему варианту вируса по дате наблюдения с последующим формальным сравнением подобранных значений β и R_0 с биологическим prior из мета-аналитической литературы.

В-третьих, одновременный прогон и формальное сравнение целочисленной SEIRD и дробной SEIRD-модели для каждой из десяти волн (см. настоящую работу далее) с применением AIC, BIC и LRT — включая явное тестирование гипотезы о значимости $\alpha_k < 1$ для каждой отдельной волны.

В-четвёртых, эмпирическое сопоставление подобранных значений α_k с известным иммунологическим контекстом соответствующих волн, выдвижение и верификация гипотезы об α_k как косвенном маркере накопленного популяционного иммунитета.

0.3.5 Дополнительные источники (к разделу 1.3)

14. Gaythorpe K. A. M., Imai N., Perez-Guzman P. N. [et al.] Data needs for better surveillance and response to infectious disease threats // Infectious Diseases of Poverty. — 2023. — Vol. 12, № 1. — Art. 43. — DOI: https://doi.org/10.1186/s40249-023-01086-z10.1186/s40249-023-01086-z.

15. Schmitz J., Lakes T., Manafa G. [et al.] Exploration of the COVID-19 pandemic at the neighborhood level in an intra-urban setting // Frontiers in Public Health. — 2023. — Vol. 11. — Art. 1128452. — DOI: https://doi.org/10.3389/fpubh.2023.112845210.3389/fpubh.2023.1128452.

16. Ли С., Сюй Ю., Ван Х. [Li S., Xu Y., Wang H. et al.] Multi-model selection and analysis for COVID-19 // Fractal and Fractional. — 2021. — Vol. 5, № 3. — Art. 120. — DOI: https://doi.org/10.3390/fractalfract503012010.3390/fractalfract5030120.

0.3.6 1.4 Цель и задачи исследования

Настоящее исследование преследует двойную цель: методологическую и содержательную. **С методологической точки** зрения цель состоит в разработке и апробации воспроизводимого аналитического конвейера ретроспективного анализа пандемии COVID-19 на основе данных рутинного санитарно-эпидемиологического надзора, применимого к малым и средним городам без специализированных регистров и геномного мониторинга. **С содержательной** — в проверке гипотезы о том, что порядок дробной производной α_k является функционально информативным параметром, отражающим не артефакт математической параметризации, а реальное нарастание популяционного иммунного фона в ходе последовательной смены волн пандемии.

Для достижения поставленной цели решались следующие задачи.

Задача 1. Формирование непрерывного ежедневного ряда заболеваемости. Исходные данные государственного надзора (формы ВП и оперативные сводки COVID-19 за 2020–2025 гг., г. Псков) **приведены к единому формату, прошли унификацию структуры и машинную импутацию пропусков** методом натуральных кубических сплайнов с ограничением монотонности накопленного числа случаев. Качество восстановленного ряда оценивалось по величине систематической ошибки на контрольных точках с известными значениями.

Задача 2. Автоматическая идентификация волн заболеваемости. Разработан **алгоритм разметки волн на основе знака сглаженной первой производной** ряда заболеваемости (гауссово ядро, $\sigma = 15$ дней) с автоматическим присвоением номеров периодам непрерывного роста. Для каждой волны рассчитаны характеристики: дата и величина пика, продолжительность, площадь под кривой (AUC), ширина на полувысоте (FWHM) и индекс асимметрии.

Задача 3. Сопоставление волн с доминирующими вариантами вируса. Составлен и верифицирован по литературным данным [4, 5] **календарь доминирования вариантов SARS-CoV-2** применительно к периоду 2020–2025 гг. на территории России. Каждому дню наблюдения присвоены биологические параметры соответствующего варианта (σ, γ, μ, β, R_0), сформировавшие информированный prior для последующей калибровки моделей.

Задача 4. Калибровка стандартной SEIRD-модели. Для каждой из десяти идентифицированных волн проведена численная калибровка целочисленной SEIRD-модели (решатель AutoVern7/Rodas5P пакета DifferencialEquationns.jl), свободные параметры: β, μ, E_0, I_0, N_eff). Разработана двухэтапная стратегия оптимизации (сеточный поиск → NelderMead → L-BFGS) с аналитическим предобусловливанием стартовой точки по скорости роста начальной фазы волны. Функция потерь — логарифмический MSE, обеспечивающий равный вклад всех фаз волны в критерий оптимальности.

Задача 5. Калибровка дробной SEIRD-модели. Разработана и откалибрована дробная SEIRD-модель с производной Капуто порядка α_k □ (0.5, 1.0] и дискретизацией по схеме Грюнвальда–Летникова. Указанная схема, при незначительном снижении точности, обладает высокой скоростью расчетов и лучше встраивается в конвейер оптимизации. Для каждой волны проведены два независимых прогона: с фиксированным $\alpha_k = 1$ (целочисленная GL-версия) и с α_k как свободным параметром (дробная версия). Параметр α_k введён через сигмоидальное преобразование $\varphi = \mathrm{logit}((\alpha_k - 0.5)/0.5)$, гарантирующее задачу без ограничений при оптимизации.

Задача 6. Формальное сравнение моделей. Для каждой волны вычислены метрики качества подгонки (RMSE, MAE, MAPE, R^2) и информационные критерии (AIC, BIC) с учётом различного числа свободных параметров у целочисленной и дробной версий. Зна-

чимость дополнительного параметра α_k проверена посредством теста отношения правдоподобия (LRT): статистика $\Lambda = n\cdot(\log MSE_int - \log MSE_frac) \sim \chi^2(1)$. Дополнительно проведён анализ структуры остатков: ACF до 21 лага и Q-Q-графики для проверки нормальности.

Задача 7. Содержательная интерпретация α_k. Выполнено сравнение подобранных значений α_k с иммунологическим и эпидемиологическим контекстом соответствующих волн: охватом вакцинации, порядковым номером волны (как прокси накопленного естественного иммунитета), биологическими характеристиками доминирующего варианта (иммунный уклон, IFR). Сформулирована и эмпирически проверена гипотеза об $\alpha_k < 1$ как маркере субдиффузионного режима, обусловленного популяционной иммунной памятью.

Объект и предмет исследования. Объект — динамика заболеваемости COVID-19 в г. Пскове (население ~200 000 чел.) за 2020–2025 гг. Предмет — сравнительная эффективность целочисленной и дробной SEIRD-моделей в ретроспективном описании последовательных волн пандемии при калибровке по данным рутинного эпидемиологического надзора.

Научная новизна. Впервые для российского малого города проведён систематический поволновой анализ пандемии COVID-19 с применением формальных критериев выбора между целочисленной и дробной SEIRD-моделями, охватывающий полный период 2020–2025 гг. и все смены доминирующих вариантов вируса. Впервые α_k предложен и верифицирован как косвенный количественный маркер нарастания популяционного иммунитета, поддающийся оценке из данных рутинного надзора без иммунологических обследований.

0.4 2. Материалы и методы

[[ux43eux431ux449ux430ux44f-ux441ux445ux435ux43cux430-ux438ux441ux441ux43bux435ux434ux43eu
ux438-ux445ux430ux440ux430ux43aux442ux435ux440ux438ux441ux442ux438ux43aux430-
ux43eux431ux44aux435ux43aux442ux430-ux43dux430ux431ux43bux44eux434ux435ux43dux438ux44f]2.1
Общая схема исследования и характеристика объекта наблюдения]

[[2.2 Предварительная обработка данных]]

[[ux438ux434ux435ux43dux442ux438ux444ux438ux43aux430ux446ux438ux44f-ux432ux43eux43bux4
ux437ux430ux431ux43eux43bux435ux432ux430ux435ux43cux43eux441ux442ux438]2.3 Идентификация волн заболеваемости]

[[2.4 Календарь доминирования штаммов]]

[[2.5 Стандартная SEIRD модель]]

[[2.6 SEIRD модель с производными дробного порядка]]

[[ux441ux442ux440ux430ux442ux435ux433ux438ux44f-ux447ux438ux441ux43bux435ux43dux43dux4
ux43eux43fux442ux438ux43cux438ux437ux430ux446ux438ux438]2.7 Стратегия численной оптимизации]

[[2.8 Сравнение результатов]]

0.4.1 2.1 Общая схема исследования и характеристика объекта наблюдения

2.1.1 Дизайн исследования Настоящая работа выполнена в формате **ретроспективного описательного исследования с элементами математического моделирования**. Временной горизонт охватывает **период с 1 января 2020 года по 31 декабря 2025 года** —

от регистрации первых случаев COVID-19 в России до завершения активной фазы пандемии на субнациональном уровне. Единицей наблюдения является один день; единицей анализа — отдельная эпидемическая волна, идентифицированная алгоритмически из непрерывного ряда ежедневной заболеваемости.

Исследование реализовано в виде **последовательного аналитического конвейера**, включающего четыре функционально обособленных этапа (рисунок 1). На **первом этапе** исходные данные государственного эпидемиологического надзора приводятся к единому формату, проходят контроль качества и восстановление пропусков. На **втором этапе** непрерывный ежедневный ряд разбивается на волны заболеваемости, каждая из которых сопоставляется с доминирующим вариантом SARS-CoV-2. На **третьем этапе** для каждой волны калибруются две конкурирующие математические модели: стандартная SEIRD с производными целого порядка и дробная SEIRD с производной Капуто порядка α_k. На **четвёртом этапе** модели формально сравниваются с применением информационных критериев и теста отношения правдоподобия, а подобранные значения α_k интерпретируются в иммунологическом контексте соответствующих волн.

Конвейер реализован **на языке Julia** 1.x [13] с использованием пакетов DataFrames.jl, CSV.jl, DifferentialEquations.jl [12] и Optim.jl. Воспроизводимость вычислительной среды обеспечивается фиксацией версий зависимостей в файле Manifest.toml. Исходный код, конфигурационные файлы и агрегированные результаты размещены в открытом репозитории (ссылка будет добавлена после слепого рецензирования).

2.1.2 Район исследования Объектом наблюдения служит население г. Пскова — административного центра Псковской области, расположенного на северо-западе Российской Федерации (координаты: 57°49′ с.ш., 28°20′ в.д.). По данным переписи 2021 года численность постоянного населения города составляет 202 879 человек, что относит его к категории малых и средних городов России (100–250 тыс. жителей). Медианный возраст населения — 42,3 года; доля лиц старше 60 лет — 26,1%, что несколько выше среднероссийского показателя и обусловлено характерной для городов данного типа возрастной структурой с отрицательным миграционным сальдо молодёжи.

С точки зрения типичности Псков представляет собой репрезентативный пример малого регионального центра северо-западного пояса России: умеренный климат с выраженной зимней сезонностью, средняя плотность населения (~1 800 чел./км² в городской черте), ограниченный промышленный сектор с преобладанием занятости в бюджетной сфере, торговле и транспорте. Близость к государственной границе Российской Федерации (~50 км до границы с Эстонией) и исторически высокая доля транзитного трафика обусловливают повышенную по сравнению со средними городами России интенсивность внешних миграционных потоков, что могло влиять на сроки завоза новых вариантов вируса.

В моделировании численность восприимчивой популяции принята равной N_{city} = 200 000 чел. (округлённое значение, соответствующее данным переписи) и используется в качестве верхней границы для оптимизируемого параметра эффективной популяции N_{eff}.

2.1.3 Источники данных Информационную основу исследования составляют два массива данных государственного эпидемиологического надзора, предоставленных Управлением Роспотребнадзора по Псковской области.

Массив 1. Еженедельный мониторинг внебольничной пневмонии (ВП). Форма федерального государственного статистического наблюдения, содержащая еженедельные данные о числе зарегистрированных случаев внебольничной пневмонии в разбивке по субъектам РФ (таблица «ВП»). Период: 2024–2025 гг. Структура файла: многоуровневые слитые заголовки (4–5 строк), даты закодированы в именах листов, а не в ячейках данных.

Массив 2. Оперативные сводки COVID-19. Ежедневные данные о заболеваемости и летальности COVID-19 в разбивке по субъектам РФ. Период: 2020–2025 гг. Файлы содержат две структурно различных части: до декабря 2020 года данные представлены в поперечном (широком) формате без явного столбца даты; начиная с декабря 2020 года — в длинном формате с явным столбцом ДАТА. Ключевые переменные: ежедневное число новых случаев, накопленное число случаев, ежедневное и накопленное число летальных исходов.

Оба массива изначально находились в формате Microsoft Excel (.xlsx) с характерными для форм государственной отчётности ограничениями: слитыми ячейками, пропусками значений вне левой верхней ячейки объединённого диапазона, русскоязычными наименованиями столбцов и непоследовательной схемой заголовков между периодами.

Дополнительным источником послужил авторский календарь доминирования вариантов SARS-CoV-2, составленный на основе публикаций систем геномного надзора и метааналитических обзоров параметров штаммов [4, 5] применительно к российскому эпидемическому контексту. Калибровочный файл (таблица `covid19_seird_params.csv`) содержит для каждого варианта: идентификатор штамма, даты начала и окончания периода доминирования (dom_start_adj, dom_end_adj), расчётные значения σ, γ, μ, β, R_0 и производных параметров (T_incub, T_infect, IFR, CFR).

2.1.4 Этические аспекты и ограничения источников данных Исследование основано исключительно на агрегированных деперсонализированных данных государственной статистической отчётности и не предполагает работы с персональными данными пациентов. В соответствии с действующим законодательством Российской Федерации прохождение этической экспертизы для данного типа исследований не требуется.

Принципиальным ограничением источников данных является системное занижение регистрируемой заболеваемости, характерное для данных рутинного надзора: регистрируются только случаи, подтверждённые лабораторно или клинически при обращении за медицинской помощью. По имеющимся оценкам для России [17], реальная заболеваемость превышала регистрируемую в 5–10 раз в различные периоды пандемии, причём коэффициент занижения существенно варьировал между волнами в зависимости от доступности тестирования и тяжести течения доминирующего варианта. Следует отметить, что занижение связано не с особенностями организации учета в Российской Федерации, а системное различие между количеством заболевших и числом манифестированных случаев, что отражает и социальный фактор (обращаемость населения в связи с наличием подозрительных симптомов, доступности диагностических тестов и т.п.).

Это обстоятельство непосредственно влияет на интерпретацию параметра N_eff: подобранные значения отражают не всю восприимчивую популяцию города, а лишь ту её долю, которая была вовлечена в регистрируемую часть эпидемического процесса. Данное ограничение учтено при обсуждении результатов (раздел 4).

Дополнительный источник (к разделу 2.1)

1 2.2 Предобработка данных

1.1 2.2.1 Первичная подготовка исходных файлов

Исходные данные поступали в формате Microsoft Excel с многоуровневыми объединёнными заголовками (4–5 строк), кириллическими наименованиями столбцов и датами, закодированными исключительно в именах листов. Для листов до декабря 2020 года использовался широкий кросс-секционный формат (одна строка на субъект), тогда как начиная с декабря 2020 года применялся длинный формат с явным столбцом ДАТА. Каждый из трёх источников — форма еженедельного мониторинга внебольничных пневмоний (ВП), оперативные сводки COVID-19 за 2020–2021 гг. и расширенные сводки за 2021–2025 гг. — требовал отдельной логики разбора.

На этапе первичной подготовки выполнялось два класса преобразований. Первый класс — структурный: унификация схем столбцов, разрешение объединённых ячеек, извлечение дат из имён листов и добавление их в качестве явного поля. Второй класс — терминологический: приведение кириллических наименований к единому английскому пространству имён согласно сводной таблице сопоставления (`column_mapping`), содержащей пять листов и охватывающей все форматы источников. Сопоставление выполнялось вручную во избежание систематических ошибок автоматического перевода специализированной медицинской терминологии. Результатом этапа служил набор структурированных таблиц в формате CSV, пригодных для прямого импорта в Julia посредством `CSV.jl` и `DataFrames.jl` [13].

1.2 2.2.2 Фильтрация по объекту исследования

Из объединённого общероссийского набора данных, охватывающего 85 субъектов Российской Федерации, был выделен подмассив, относящийся к Псковской области, по составному ключу (,). После фильтрации итоговый временно́й ряд охватывал период с 17 марта 2020 года по 30 декабря 2024 года, что в совокупности составило 1750 наблюдений. Базовыми переменными анализа служили: накопленное число подтверждённых случаев COVID-19 (`total`), ежедневный прирост (`daily`), накопленное число летальных исходов (`deaths_total`) и ежедневное число смертей (`deaths_daily`).

1.3 2.2.3 Восстановление непрерывного временно́го ряда

Ранние сводки (март–ноябрь 2020 года) публиковались с нерегулярной, преимущественно еженедельной периодичностью, что порождало систематические пропуски в ряду ежедневных приростов. Оперативные данные за последующие периоды, хотя и публиковались ежедневно, содержали спорадические пропуски вследствие задержек отчётности.

Восстановление непрерывного ряда выполнялось в два этапа. На первом этапе к накопленному числу случаев (`total`) применялась интерполяция натуральными кубическими сплайнами по индексам наблюдений с известными значениями, что обеспечивало гладкость второго порядка в узлах интерполяции. Коэффициенты кубического полинома в каждом интервале вычислялись из системы уравнений, задающей условия непрерывности

функции, первой и второй производных, при естественных граничных условиях (нулевая вторая производная на концах). На втором этапе восстановленный ряд `total_interp` принудительно переводился в неубывающий: при обнаружении убывающего фрагмента — возможного артефакта интерполяции — значение заменялось предшествующим максимумом. Это условие физически обосновано: накопленное число случаев является монотонно неубывающей функцией времени.

Ежедневный поток новых случаев восстанавливался как первая конечная разность интерполированного накопленного ряда:

$$\Delta t \ = total_{interp}(t) - total_{interp}(t-1), \Delta_1 \ = 0.$$

Полученная переменная (`daily_interp`) служила основной наблюдаемой при дальнейшем сглаживании и моделировании.

1.4 2.2.4 Сглаживание

Ряд `daily_interp` подвергался двум независимым процедурам сглаживания, результаты которых использовались для различных аналитических задач. Первая процедура — скользящее среднее с каузальным окном 18 дней (`daily_interp_smooth`) — применялась для предварительной визуализации и построения стратифицированных по волнам панелей. Выбор ширины окна продиктован компромиссом между подавлением недельной периодичности отчётности (7-дневный цикл) и сохранением межволновой структуры с характерным масштабом порядка нескольких месяцев.

Вторая процедура — свёртка с нормированным гауссовым ядром (стандартное отклонение σ = 15 дней, усечение при |t| > 3σ) с коррекцией граничных эффектов — давала ряд `daily_interp_gauss`, использовавшийся для автоматической идентификации волн (раздел 2.3) и оценки положения пиков. Граничная коррекция реализовывалась перенормировкой весов на неполном окне, что исключало систематический сдвиг оценок в начале и конце ряда. Параметр σ = 15 дней обеспечивал подавление флуктуаций с периодом менее двух недель при сохранении временнóго разрешения, достаточного для различения волн длительностью 6–12 недель.

2 2.3 Идентификация волн заболеваемости

2.1 2.3.1 Оценка сглаженной первой производной

Границы волн определялись по смене знака первой производной ряда `daily_interp_gauss`. Непосредственное дифференцирование сглаженного ряда нецелесообразно ввиду накопления ошибок конечных разностей на коротких временных масштабах; поэтому применялась двухшаговая процедура. На первом шаге вычислялась числовая производная по схеме центральных разностей второго порядка точности:

$$\dot{y}_t = \frac{y_{t+1} - y_{t-1}}{2}, \quad t = 2, \ldots, n-1,$$

с односторонними разностями первого порядка на граничных точках. На втором шаге полученный ряд $\dot{y}$ повторно сглаживался свёрткой с нормированным гауссовым ядром (σ = 15 дней, усечение при |τ| > 3σ) с той же граничной коррекцией, что и в разделе 2.2.4. Результирующий ряд `daily_interp_deriv_smooth` представляет собой оценку локальной скорости изменения заболеваемости, устойчивую к высокочастотным флуктуациям

отчётности. Знак производной фиксировался как +1 (рост), −1 (спад) или 0 (нулевой градиент); нулевые значения заменялись знаком ближайшего предшествующего ненулевого наблюдения, а начальный префикс из нулей — знаком первого ненулевого элемента.

2.2 2.3.2 Автоматическая разметка волн

Последовательная разметка волн осуществлялась детерминированным автоматом на основе ряда знаков производной. Автомат поддерживал два состояния: `:up` (фаза роста) и `:down` (фаза спада). Переход `:idle → :up` при обнаружении первого знака «+1» инициировал новую волну с инкрементом счётчика; последующая смена знака на «−1» переводила автомат в состояние `:down` без изменения номера текущей волны. Таким образом, каждая волна охватывала непрерывный интервал, включающий фазу роста и примыкающую фазу спада вплоть до следующего перехода в фазу роста. Каждому наблюдению присваивался целочисленный номер волны, начиная с 1; наблюдения до первого обнаруженного роста помечались нулём и исключались из дальнейшего волнового анализа.

Описанный подход эквивалентен разбиению временно́го ряда на монотонные отрезки с последующим объединением каждой пары «подъём + спуск» в единую волну. Его принципиальное преимущество перед пороговыми методами (например, выделение периодов, в которых заболеваемость превышает фиксированную долю максимума) состоит в отсутствии зависимости от абсолютного уровня заболеваемости, что особенно важно при сравнении волн с существенно различающейся амплитудой.

2.3 2.3.3 Характеристики волн

Для каждой идентифицированной волны вычислялся набор количественных характеристик на основе ряда `daily_interp_gauss`. Положение пика определялось как индекс глобального максимума внутри волнового интервала. Временны́е границы волны уточнялись алгоритмом водораздела (watershed): каждому индексу временного ряда ставился в соответствие ближайший пик по метрике, учитывающей как временно́е расстояние, так и высоту пика,

$$j^*(i) = \arg\min_{p \in \mathcal{P}} \frac{|i - p|}{y_p},$$

где $\mathcal{P}$ — множество индексов пиков, y_p — значение ряда в пике p. Границы волны определялись как крайние индексы, принадлежащие данному водоразделу и превышающие базовый уровень $y_{\min} + 0{,}002 \cdot (y_{\max} - y_{\min})$.

На основании уточнённых границ $[t_{start}, t_{stop}]$ и положения пика t_{peak} рассчитывались следующие характеристики:

— **Продолжительность** (duration_days): $t_{stop} - t_{start} + 1$ дней.

— **Площадь под кривой выше базового уровня** (auc_above_base): $\sum_{t=t_{start}}^{t_{stop}} (y_t - y_{base})$, пропорциональна суммарной нагрузке волны.

— **Полная ширина на полувысоте** (FWHM): расстояние между последним индексом слева от пика, где $y_t \leq y_{peak}/2$, и первым таким индексом справа; характеризует концентрацию нагрузки во времени независимо от общей длительности волны.

— **Асимметрия** (asymmetry): отношение $(t_{peak} - t_{start}) / \max(t_{stop} - t_{peak}, 1)$; значение больше единицы указывает на более длинный правый хвост (медленный спад), меньше единицы — на более длинный левый хвост (медленный подъём).

— **Выступ пика** (prominence): превышение высоты пика над уровнем, до которого необходимо опустить ряд, чтобы пик слился с соседним более высоким пиком или краем ряда; вычислялся по стандартному алгоритму `peakproms` из пакета `Peaks.jl`. Параметр использовался как фильтр при первоначальном отборе пиков: минимальный допустимый выступ составлял 0,5 % размаха ряда, минимальное расстояние между соседними пиками — 11 дней.

Совокупность перечисленных характеристик формировала таблицу волн, служившую основой для стратификации данных перед калибровкой SEIRD-моделей (раздел 2.5–2.6) и для сравнительного анализа эпидемических параметров между волнами (раздел 3).

3 2.4 Календарь доминирования вариантов SARS-CoV-2

3.1 2.4.1 Составление базы параметров штаммов

Для привязки биологических характеристик возбудителя к каждому дню наблюдения был составлен авторский календарь доминирования вариантов SARS-CoV-2, охватывающий период с марта 2020 по декабрь 2024 года. Источниками параметров служили систематические обзоры и метаанализы по инкубационному периоду, серийному интервалу и времени генерации [4, 5], а также первичные публикации систем геномного надзора, документирующие смену доминирующих линий в России и сопредельных странах.

Для каждого варианта в таблице `covid19_seird_params.csv` зафиксированы следующие поля. Идентификационные: `strain_id` (уникальный строковый ключ), `strain_name` (общепринятое название), `pango_lineage` (классификация Pango), `dom_start_adj` и `dom_end_adj` (скорректированные даты начала и окончания периода доминирования). Биологические параметры: `R0_min`, `R0_avg`, `R0_max` — диапазон базового репродуктивного числа; `T_incub_avg_days` — средняя длительность латентного периода с соответствующей скоростью экспонирования $\sigma = 1/T_{incub}$ (поле `sigma_avg_per_day`); `T_infect_avg_days` — средняя длительность инфекционного периода с соответствующей скоростью выздоровления $\gamma = 1/T_{infect}$ (поле `gamma_avg_per_day`); `IFR_avg` — среднее значение инфекционной летальности с производной скоростью смерти $\mu = IFR \cdot \gamma/(1-IFR)$ (поле `mu_avg_per_day`); `beta_min_per_day`, `beta_avg_per_day`, `beta_max_per_day` — диапазон скорости передачи, рассчитанный как $\beta = R_0 \cdot (\gamma + \mu)$; `T_gen_avg_days` — среднее время генерации. Качественные признаки: `severity` (относительная клиническая тяжесть) и `immune_escape` (способность варианта уклоняться от выработанного иммунного ответа).

Значения параметров для предкового уханьского варианта, Alpha и Delta заимствованы из метаанализа Xu et al. [4], охватывающего 147 исследований по временны́м параметрам передачи; для Omicron и его субвариантов (BA.1, BA.2, BA.4/5, XBB, JN.1 и поздних линий) дополнительно привлечены данные Madewell et al. [5]. Для периодов, не охваченных указанными метаанализами, параметры экстраполировались на основании тенденций укорочения серийного интервала, задокументированных при последовательной смене линий Omicron.

3.2 2.4.2 Развёртка в ежедневный календарь

Исходная таблица параметров содержала по одной строке на вариант с интервальными датами доминирования. Для последующего объединения с ежедневным рядом заболеваемости каждая строка была развёрнута в набор однодневных записей: для каждой пары `(dom_start_adj, dom_end_adj)` генерировался непрерывный перечень дат с шагом один день, каждой из которых присваивались все параметры соответствующего варианта.

Результирующая промежуточная таблица `strain_daily` содержала по одной строке на каждый день активности каждого варианта.

3.3 2.4.3 Разрешение перекрытий

Временны́е интервалы доминирования смежных вариантов в ряде случаев перекрываются: новый вариант достигает порога доминирования прежде, чем предыдущий полностью вытесняется из циркуляции. При объединении по дате это порождает неоднозначность — несколько строк на одну дату. Для её устранения применялось детерминированное правило приоритета: при наличии нескольких вариантов, активных в одну дату, сохранялась запись с наиболее поздним значением `dom_start_adj`, то есть вариант с более поздним началом доминирования считался актуальным. При равенстве этой даты использовался порядковый номер варианта `strain_num` как вторичный ключ сортировки. Каждой записи присваивалась метка типа сопоставления: `"exact"` при отсутствии перекрытий или `"overlap_resolved"` при их наличии, а также счётчик `n_matching_strains`. Результирующая таблица `strain_daily_resolved` содержала ровно одну строку на дату, покрывая весь период наблюдений.

3.4 2.4.4 Присоединение к ряду заболеваемости

Таблица `strain_daily_resolved` была присоединена к основному ежедневному ряду заболеваемости операцией левого соединения (`leftjoin`) по ключу `date`. Результирующий обогащённый DataFrame `df_enriched` содержал для каждого дня наблюдения как эпидемиологические переменные (`daily_interp`, `daily_interp_smooth`, номер волны и производные), так и биологические параметры доминирующего варианта (σ, γ, μ, β, R_0). Дни, выходящие за пределы охвата календаря штаммов, получали `missing` по всем полям варианта и при калибровке моделей не использовались.

Таким образом, для каждой волны, идентифицированной в разделе 2.3, оказывались известны априорные значения скоростей σ и γ, служившие фиксированными параметрами при калибровке SEIRD-моделей (разделы 2.5–2.6), а значения β_{avg} и μ_{avg} — справочными стартовыми точками оптимизации.

4 2.5 Стандартная SEIRD-модель

4.1 2.5.1 Структура модели

Динамика эпидемической волны описывалась детерминированной компартментной моделью SEIRD с пятью состояниями: восприимчивые (S), экспонированные (E, инфицированные, но ещё не заразные), инфекционные (I), выздоровевшие (R) и летальные (D). Популяция предполагается замкнутой с эффективным размером N_{eff}, так что в любой момент времени выполняется условие сохранения:

$$S(t) + E(t) + I(t) + R(t) + D(t) = N_{eff}.$$

Система ОДУ имеет вид:

$$\frac{dS}{dt} = -\frac{\beta, I}{N_{eff}}, S,$$

$$\frac{dE}{dt} = \frac{\beta, I}{N_{eff}}, S - \sigma, E,$$

$$\frac{dI}{dt} = \sigma, E - (\gamma + \mu), I,$$

$$\frac{dR}{dt} = \gamma, I,$$

$$\frac{dD}{dt} = \mu, I,$$

где β — скорость передачи инфекции (сут$^{-1}$), $\sigma = 1/T_{incub}$ — скорость экспонирования (сут$^{-1}$), $\gamma = 1/T_{infect}$ — скорость выздоровления (сут$^{-1}$), μ — скорость летальных исходов (сут$^{-1}$). Базовое репродуктивное число для данной конфигурации параметров выражается как:

$$R_0 = \frac{\beta}{\gamma + \mu}.$$

Выбор структуры SEIRD обусловлен необходимостью явно моделировать как латентную фазу инфекции — принципиально важную для SARS-CoV-2 с его характерным инкубационным периодом от 2 до 6 дней [4] — так и летальные исходы в качестве второй независимой наблюдаемой, что существенно снижает сложность идентификации параметров, описанную в работе [3].

4.2 2.5.2 Параметры модели и их разделение

Параметры модели разделялись на два класса: фиксированные, задаваемые из внешнего источника, и свободные, подбираемые в ходе оптимизации.

К **фиксированным** относились скорости σ и γ, берущиеся непосредственно из поля `sigma_avg_per_day` и `gamma_avg_per_day` таблицы `df_enriched` для преобладающего штамма данной волны (раздел 2.4). Это решение согласуется с рекомендацией Королёва [3] о целесообразности фиксации биологически обоснованных параметров для устранения вырожденности оптимизационной задачи.

Свободными параметрами служили: β — скорость передачи, μ — скорость летальных исходов, $E_0 = E(t_0)$ и $I_0 = I(t_0)$ — начальные размеры экспонированного и инфекционного компартментов, а также N_{eff} — эффективный размер восприимчивой популяции. Таким образом, вектор свободных параметров содержал пять компонент:

$$\theta = (\beta, ; \mu, ; E_0, ; I_0, ; N_{eff}).$$

Параметр N_{eff} интерпретируется как размер той доли популяции, которая фактически участвовала в передаче инфекции в данной волне, и ограничивался сверху численностью города: $N_{eff} \leq N_{city} = 200,000$. Занижение регистрируемых случаев (раздел 2.1.4) означает, что подобранное N_{eff} отражает не всю биологически восприимчивую популяцию, а лишь ту её часть, которая генерировала наблюдаемый поток зарегистрированных случаев. Этот эффект систематически обсуждается в разделе 4.

Начальные условия для S, R и D определялись из условия сохранения и нулевых начальных значений: $S(t_0) = N_{eff} - E_0 - I_0$, $R(t_0) = 0$, $D(t_0) = 0$.

4.3 2.5.3 Наблюдаемые и функция потерь

Модель сопоставлялась с двумя независимыми наблюдаемыми рядами. Первый — ежедневный поток новых клинически значимых случаев — аппроксимировался скоростью выхода из компартмента E:

$$\hat{c}(t) = \sigma, E(t).$$

Второй — ежедневное число летальных исходов — аппроксимировалось скоростью выхода из компартмента I по летальному пути:

$$\hat{d}(t) = \mu, I(t).$$

Наблюдаемыми служили восстановленные ряды `daily_interp` и `deaths_daily` для соответствующей волны. В случаях, когда данные о смертях для отдельных суток отсутствовали, пропуски заменялись нулём. Функция потерь определялась как логарифмический среднеквадратический error по случаям:

$$\mathcal{L}(\theta) = \frac{1}{T}\sum_{t=1}^{T}(\ln(1+\hat{c}(t;\theta)) - \ln(1+c(t)))^2,$$

где $c(t)$ — наблюдаемый ежедневный прирост, T — длина волны в сутках. Логарифмическое преобразование обосновано тем, что ошибки на пике волны и в её хвосте имеют принципиально различный абсолютный масштаб: минимизация обычного MSE концентрирует оптимизацию на нескольких точках вблизи пика, тогда как log-MSE обеспечивает сбалансированный вклад восходящей фазы, пика и нисходящего хвоста — трёх структурно различных частей волны, несущих различную информацию о параметрах модели.

4.4 2.5.4 Численное решение

Система ОДУ решалась численно с использованием пакета DifferentialEquations.jl [12] для языка Julia [13]. В качестве решателя использовался адаптивный метод `AutoVern7(Rodas5P)`, автоматически переключающийся между нежёстким высокоточным интегратором Верне седьмого порядка (Vern7) и жёстким решателем Розенброка пятого порядка (Rodas5P) в зависимости от локальной жёсткости системы. Шаг сохранения результата составлял $h_{save} = 1$ день; абсолютный и относительный допуски интегрирования — 10^{-8} и 10^{-6} соответственно. При каждом обращении решателя в ходе оптимизации все пять свободных параметров передавались через вектор p, а состояние системы в момент $t = 0$ формировалось из E_0, I_0 и N_{eff} аналитически.

Для обеспечения вычислительной устойчивости в ходе оптимизации все свободные параметры параметризовались в логарифмическом пространстве: $\tilde{\theta}_i = \ln\theta_i$, что автоматически гарантировало их положительность и существенно улучшало обусловленность задачи при больших вариациях масштабов параметров. Стратегия численной оптимизации описана в разделе 2.7.

5 2.6 SEIRD-модель с производными дробного порядка

5.1 2.6.1 Производная Капуто и её эпидемиологическая интерпретация

Дробная SEIRD-модель формулируется посредством замены производных целого порядка в системе раздела 2.5 на производные Капуто порядка $\alpha_k \in (0{,}5; , 1{,}0]$. Производная Капуто порядка α от функции f в момент t определяется как [6, 7]:

$$^{!C}D^{\alpha}f(t) = \frac{1}{\Gamma(1-\alpha)}\int_0^t \frac{f'(\tau)}{(t-\tau)^{\alpha}}, d\tau, \quad \alpha \in (0,1),$$

где $\Gamma(\cdot)$ — гамма-функция, а интеграл берётся по всей предыстории процесса от начального момента до t. В отличие от производной Римана–Лиувилля, производная Капуто допускает постановку начальных условий в классической форме — значениями функции $f(0)$, — что делает её естественным выбором для задач Коши в динамических системах [7].

Ключевое свойство оператора, существенное для данного применения, состоит в следующем: при $\alpha < 1$ ядро памяти $(t-\tau)^{-\alpha}$ убывает по степенно́му закону, а не экспоненциально. Это означает, что состояние системы в момент t явно зависит от всей её истории с начала волны, причём вклад прошлых состояний убывает медленнее, чем в стандартной ОДУ. Применительно к эпидемической динамике такое поведение может отражать накопленный популяционный иммунитет, гетерогенность контактных сетей и поведенческие изменения, не сбрасываемые при переходе между волнами, — факторы, которые создают устойчивую зависимость текущей скорости распространения от накопленного иммунного опыта. При $\alpha_k \to 1$ степенно́е ядро вырождается в дельта-функцию Дирака, и дробная система тождественно переходит в целочисленную SEIRD раздела 2.5.

5.2 2.6.2 Структура дробной системы

Дробная SEIRD-модель для волны k определяется системой:

$$^{!C}D^{\alpha_k}S = -\frac{\beta, I}{N_{eff}}, S,$$

$$^{!C}D^{\alpha_k}E = \frac{\beta, I}{N_{eff}}, S - \sigma, E,$$

$$^{!C}D^{\alpha_k}I = \sigma, E - (\gamma + \mu), I,$$

$$^{!C}D^{\alpha_k}R = \gamma, I,$$

$$^{!C}D^{\alpha_k}D = \mu, I,$$

где параметры σ, γ фиксированы из календаря штаммов аналогично разделу 2.5, а правые части совпадают с целочисленной версией. Единый порядок α_k применяется ко всем пяти уравнениям системы, что обеспечивает сохранение условия замкнутости популяции [8]: при любом $\alpha_k \in (0,1]$ сумма $S+E+I+R+D = N_{eff}$ остаётся постоянной, поскольку правые части системы суммируются в нуль тождественно.

5.3 2.6.3 Дискретизация по схеме Грюнвальда–Летникова

Для численного решения системы применялась явная схема Грюнвальда–Летникова (GL) с шагом $h = 1$ день. Дискретный аналог производной Капуто порядка α в точке $t_n = nh$ записывается как [6, 8]:

$$^{!C}D_h^{\alpha} f(t_n) \approx h^{-\alpha} \sum_{j=0}^{n} w_j^{(\alpha)}, f(t_{n-j}),$$

где GL-веса $w_j^{(\alpha)}$ определяются рекуррентно:

$$w_0^{(\alpha)} = 1, \qquad w_j^{(\alpha)} = w_{j-1}^{(\alpha)} \cdot \frac{j-1-\alpha}{j}, \quad j = 1, 2, \ldots$$

При $\alpha < 1$ веса $w_j^{(\alpha)}$ знакочередуются: $w_0 = 1 > 0$, $w_1 = -\alpha < 0$, далее убывают по абсолютной величине как $O(j^{-1-\alpha})$. Это выражает степенно́е затухание памяти: вклад состояния в момент t_{n-j} убывает как $j^{-1-\alpha}$ с ростом лага j, тогда как экспоненциальное ядро давало бы экспоненциальное затухание.

Схема GL первого порядка точности по h: глобальная ошибка $O(h)$ [9]. При $h = 1$ день и характерных временны́х масштабах волн порядка 30–120 дней это обеспечивает приемлемую точность. На каждом шаге n вычисляется полная сумма по всем предшествующим значениям компартментов, что требует хранения всей истории волны; вычислительная сложность составляет $O(T^2)$ по числу шагов T. Для волн длительностью до 150 дней при однодневном шаге это приводит к не более чем $\sim 10^4$ операций умножения на шаг, что при пятикомпонентной системе остаётся вычислительно незначительным.

5.4 2.6.4 Свободные параметры и ограничения

Вектор свободных параметров дробной модели расширен относительно целочисленной на один элемент — порядок производной α_k:

$$\theta^{(frac)} = (\beta, ; \mu, ; E_0, ; I_0, ; N_{eff}, ; \alpha_k).$$

Нижняя граница $\alpha_k > 0{,}5$ введена из содержательных соображений: при $\alpha_k \leq 0{,}5$ память ядра становится настолько длинной, что ранние фазы эпидемии начинают доминировать над текущей динамикой, утрачивая биологический смысл применительно к отдельным волнам. Верхняя граница $\alpha_k = 1$ обеспечивает гнездование моделей: целочисленная SEIRD является частным случаем дробной при $\alpha_k = 1$, что позволяет применять тест отношения правдоподобия для формальной проверки значимости дробного расширения (раздел 2.8).

При оптимизации α_k параметризовался через сигмоидальное преобразование, отображающее R в интервал $(0{,}5; , 1{,}0]$:

$$\alpha_k = 0{,}5 + 0{,}5 \cdot \sigma(\tilde{\alpha}), \qquad \sigma(\tilde{\alpha}) = \frac{1}{1 + e^{-\tilde{\alpha}}},$$

где $\tilde{\alpha} \in R$ — неограниченный оптимизируемый параметр. Остальные пять параметров параметризовались в логарифмическом пространстве аналогично разделу 2.5.4. Функция потерь и стратегия оптимизации для дробной модели идентичны описанным в разделах 2.5.3 и 2.7 соответственно.

6 2.7 Стратегия численной оптимизации

6.1 2.7.1 Постановка задачи и общий план

Калибровка обеих моделей сводилась к минимизации функции потерь $\mathcal{L}(\theta)$ (раздел 2.5.3) по вектору свободных параметров θ при следующих ограничениях: все параметры строго положительны; $N_{eff} \leq N_{city} = 200,000$; $N_{eff} \geq E_0 + I_0 + 1$; $\alpha_k \in (0{,}5; , 1{,}0]$ (только для дробной модели). Ландшафт $\mathcal{L}$ невыпуклый: наблюдается как минимум один глубокий «физически осмысленный» минимум вблизи корректных биологических параметров, окружённый пологими долинами с численно приемлемыми, но биологически вырожденными решениями (например, $N_{eff} \to N_{city}$ при $\beta \to 0$). Для надёжного нахождения глобального минимума применялась трёхступенчатая процедура: аналитическое предобусловливание стартовой точки, двумерный сеточный поиск и финальная градиентная полировка.

6.2 2.7.2 Параметризация и граничные условия

Все компоненты вектора $\theta = (\beta, \mu, E_0, I_0, N_{eff})$ передавались оптимизатору в логарифмическом пространстве: $\tilde{\theta}_i = \ln \theta_i$. Это автоматически гарантирует строгую положительность, устраняет масштабную несоразмерность между $\beta \sim 10^{-1}$ и $N_{eff} \sim 10^4$, а также приближает ландшафт $\mathcal{L}(\tilde{\theta})$ к более симметричной форме в окрестности минимума. Ограничение $N_{eff} \leq N_{city}$ реализовывалось возвратом штрафного значения $\mathcal{L} = 10^{18}$ при его нарушении. Для дробной модели параметр α_k вводился через сигмоидальное преобразование (раздел 2.6.4) и оптимизировался совместно с остальными компонентами вектора.

6.3 2.7.3 Аналитический предварительный выбор стартовой точки

Качество начального приближения принципиально определяет эффективность последующей оптимизации. Для его получения применялась система аналитических оценок, основанных на наблюдаемых характеристиках волны.

Оценка скорости роста. Из ранней восходящей фазы волны методом наименьших квадратов в логарифмической шкале оценивалась экспоненциальная скорость роста r_{est}. При линеаризации SEIRD-системы вблизи начального состояния $(S \approx N_{eff}, ; E, I \ll N_{eff})$ характеристический показатель роста определяется соотношением, из которого непосредственно следует оценка скорости передачи:

$$\hat{\beta} = \frac{(r_{est} + \sigma)(r_{est} + \gamma + \mu)}{\sigma}.$$

Оценка эффективной популяции. В рамках классической теории компартментных моделей [1, 2] финальный размер эпидемии $z = 1 - S(\infty)/N_{eff}$ связан с R_0 трансцендентным уравнением. Из наблюдаемого числа случаев до пика волны C_{peak} и оценки $\hat{R}_0 = \hat{\beta}/(\gamma + \mu)$ выводилась приближённая оценка:

$$\hat{N}_{eff} = \frac{C_{peak} \cdot \hat{R}_0}{\hat{R}_0 - 1},$$

ограниченная снизу удвоенным суммарным числом случаев волны и сверху N_{city}.

Оценка начальных условий. Начальный размер инфекционного компартмента оценивался обратной экстраполяцией от пика:

$$\hat{I}_0 = \max!(0{,}5, ; I_{peak} \cdot e^{-r_{est} \cdot t_{peak}}),$$

где $I_{peak} = c_{max}/(\gamma + \mu)$, c_{max} — максимум наблюдаемого ежедневного прироста, t_{peak} — индекс дня пика. Начальный экспонированный компартмент определялся из стационарного соотношения SEIR в фазе роста: $\hat{E}_0 = \hat{I}_0 \cdot (\gamma + \mu)/\sigma$.

6.4 2.7.4 Двумерный сеточный поиск

Аналитические оценки $\hat{\beta}$ и $\hat{N}_{eff}$ служили центрами двумерных логарифмических сеток. Для β строилась сетка из 20 точек в диапазоне $[\hat{\beta}/4, ; 4\hat{\beta}]$; для N_{eff} — из 20 точек в диапазоне $[\max(1{,}5 \cdot C_{total}, ; 5), ; N_{city}]$, где C_{total} — суммарное число случаев волны. На каждом из 400 узлов сетки функция потерь вычислялась при $\mu = \mu_{prior}$ и аналитически вычисленных E_0, I_0, зависящих от текущего β и N_{eff}. Узел с минимальным значением $\mathcal{L}$ давал стартовую точку θ_0 для последующей оптимизации. Этот шаг принципиально важен: он позволяет избежать ухода результатов оптимизации NelderMead в биологически бессмысленные области ландшафта.

6.5 2.7.5 Двухэтапная финальная оптимизация

Этап 1 — NelderMead с мультистартом. От стартовой точки θ_0 запускалось 15 независимых прогонов метода Нелдера–Мида [13]: один прогон из θ_0 и 14 прогонов из возмущённых стартов $\theta_0 + \varepsilon_i$, где компоненты ε_i являлись независимыми гауссовыми возмущениями с асимметричными масштабами: $\sigma_{\tilde{\beta}} = 0{,}3$, $\sigma_{\tilde{\mu}} = 0{,}8$, $\sigma_{\tilde{E}_0} = \sigma_{\tilde{I}_0} = 1{,}0$, $\sigma_{\tilde{N}} = 0{,}4$. Бóльшие масштабы возмущений для E_0 и I_0 отражают их худшую определённость из наблюдаемых данных относительно β и N_{eff}. Каждый прогон выполнялся до 6,000 итераций при допуске $g_{tol} = 10^{-8}$; по завершении всех стартов отбирались три кандидата с наименьшим $\mathcal{L}$.

Воспроизводимость мультистарта обеспечивалась инициализацией генератора случайных чисел фиксированным зерном, зависящим от номера волны: $seed = SEED + k$, где $SEED$ — константа проекта.

Этап 2 — L-BFGS. Каждый из трёх кандидатов передавался в квазиньютоновский метод L-BFGS (до 10,000 итераций, $g_{tol} = 10^{-10}$) для уточнения в окрестности минимума. Финальным результатом считался вектор с наименьшим $\mathcal{L}$ среди трёх уточнённых решений. Метод L-BFGS обеспечивает суперлинейную сходимость вблизи гладкого минимума при существенно меньших вычислительных затратах, чем полный метод Ньютона, благодаря низкоранговому приближению гессиана [13].

6.6 2.7.6 Взвешивание наблюдаемых

Функция потерь включала два слагаемых — по случаям и по смертям. В волнах, для которых суммарное число летальных исходов превышало 5, слагаемое по смертям вводилось с весовым коэффициентом $w_d = 3{,}0$:

$$\mathcal{L}(\theta) = \mathcal{L}_c(\theta) + w_d \cdot \mathcal{L}_d(\theta),$$

где $\mathcal{L}_c$ и $\mathcal{L}_d$ — log-MSE по случаям и смертям соответственно. В волнах с малым числом смертей (≤ 5) устанавливалось $w_d = 0$, поскольку случайная вариация отдельных

регистрируемых смертей привела бы к неустойчивости оценки μ. Тройной вес при достаточном числе смертей обусловлен тем, что ежедневная смертность несёт независимую информацию о параметре μ, существенно снижая его коллинеарность с β и N_{eff}.

7 2.8 Сравнение моделей

7.1 2.8.1 Метрики качества подгонки

Для каждой волны k и каждой из двух моделей вычислялся стандартный набор метрик качества подгонки по ряду ежедневных новых случаев. Пусть c_t — наблюдаемый прирост, $\hat{c}_t$ — модельное предсказание, T — длина волны в сутках.

Среднеквадратическое отклонение:

$$RMSE = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(c_t - \hat{c}_t)^2}.$$

Средняя абсолютная ошибка:

$$MAE = \frac{1}{T}\sum_{t=1}^{T}|c_t - \hat{c}_t|.$$

Средняя абсолютная процентная ошибка, вычисляемая в исходном масштабе:

$$MAPE = \frac{100}{T}\sum_{t=1}^{T}\frac{|c_t - \hat{c}_t|}{\max(c_t, 1)},$$

где знаменатель ограничен снизу единицей во избежание деления на нуль в периоды нулевой регистрации. Коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_t (c_t - \hat{c}_t)^2}{\sum_t (c_t - \bar{c})^2},$$

где $\bar{c}$ — выборочное среднее наблюдаемого ряда. Наконец, логарифмический MSE, служащий целевым функционалом при оптимизации (раздел 2.5.3), вычислялся и как диагностическая метрика для сопоставления между волнами:

$$\mathcal{L} = \frac{1}{T}\sum_{t=1}^{T}(\ln(1 + \hat{c}_t) - \ln(1 + c_t))^2.$$

Все метрики вычислялись отдельно для целочисленной модели ($\mathcal{M}_{int}$, 5 параметров) и дробной ($\mathcal{M}_{frac}$, 6 параметров).

7.2 2.8.2 Информационные критерии

Для сравнения моделей с различным числом параметров применялись информационные критерии AIC и Байесовский, построенные на основе log-MSE как суррогата логарифма правдоподобия. При предположении о нормально распределённых ошибках в логарифмическом масштабе логарифм правдоподобия пропорционален $-T \cdot \mathcal{L}/2$, откуда:

$$AIC = T \cdot \ln(\mathcal{L}) + 2k,$$

$$BIC = T \cdot \ln(\mathcal{L}) + k \cdot \ln(T),$$

где $k = 5$ для целочисленной модели и $k = 6$ для дробной. Разности $\Delta AIC = AIC_{int} - AIC_{frac}$ и $\Delta BIC = BIC_{int} - BIC_{frac}$ интерпретировались по стандартным шкалам: $\Delta > 10$ — существенное свидетельство в пользу дробной модели; $2 < \Delta \leq 10$ — умеренное; $|\Delta| \leq 2$ — модели практически неразличимы. Критерий BIC штрафует дополнительный параметр α_k строже, чем AIC, при $T > 7$ (что выполняется для всех волн), что делает его более консервативной мерой оценки улучшения качества.

7.3 2.8.3 Тест отношения правдоподобия

Поскольку целочисленная SEIRD является частным случаем дробной при $\alpha_k = 1$ (гнездование моделей), для формальной проверки гипотезы $H_0\colon \alpha_k = 1$ применялся тест отношения правдоподобия (LRT). Статистика теста строилась из значений log-MSE обеих моделей на одних и тех же данных волны:

$$\Lambda_k = T \cdot (\ln \mathcal{L}_{int} - \ln \mathcal{L}_{frac}).$$

При верной H_0 и при достаточно большом T статистика Λ_k асимптотически следует распределению $\chi^2(1)$, поскольку число дополнительных свободных параметров дробной модели равно одному (α_k). Порог значимости принимался равным $p < 0{,}05$, что соответствует $\Lambda_k > 3{,}84$. Дополнительно вычислялось скорректированное p-значение с поправкой Бонферрони на множественные сравнения по 10 волнам ($p_{adj} < 0{,}005$, $\Lambda_k > 7{,}88$).

Условие $\mathcal{L}_{frac} \leq \mathcal{L}_{int}$ выполняется всегда по конструкции: дробная модель содержит целочисленную как частный случай, поэтому её минимум функции потерь не может быть хуже. Таким образом, $\Lambda_k \geq 0$, и LRT проверяет лишь статистическую значимость наблюдаемого улучшения с учётом размера выборки T.

7.4 2.8.4 Анализ остатков

Для диагностики систематических расхождений между моделью и данными вычислялись нормированные остатки в логарифмическом масштабе:

$$e_t = \ln(1 + c_t) - \ln(1 + \hat{c}_t), \quad t = 1, \ldots, T.$$

Для ряда e_t строились: выборочная автокорреляционная функция (ACF) при лагах $1, \ldots, 14$ с границей значимости $\pm 1{,}96/\sqrt{T}$; квантиль-квантильный график (Q-Q) с теоретическим нормальным распределением. Значительные пики ACF за пределами границы значимости указывают на систематическую недо- или сверхоценку модели на отдельных фазах волны. Статистическая проверка нормальности не производилась ввиду заведомо ограниченного числа наблюдений ($T \approx 30$–150) и известной несимметричности эпидемических волн: анализ ACF и Q-Q использовался как описательный инструмент для сравнения качества остатков целочисленной и дробной моделей, а не как формальный тест.

Сводная таблица результатов по всем десяти волнам включала: номер волны, доминирующий штамм, длину ряда T, значения RMSE, R^2, ΔAIC, ΔBIC, Λ_k, p-значение LRT и подобранный $\hat{\alpha}_k$ для дробной модели.

7.5 Результаты

[[ux43eux43fux438ux441ux430ux442ux435ux43bux44cux43dux430ux44f-ux445ux430ux440ux430ux43aux
ux432ux440ux435ux43cux435ux43dux43dux43eux433ux43e-ux440ux44fux434ux430-ux438-
ux438ux434ux435ux43dux442ux438ux444ux438ux43aux430ux446ux438ux44f-ux432ux43eux43bux43d]3.1
Описательная характеристика временного ряда и идентификация волн]

[[ux440ux435ux437ux443ux43bux44cux442ux430ux442ux44b-ux43aux430ux43bux438ux431ux440ux4
ux441ux442ux430ux43dux434ux430ux440ux442ux43dux43eux439-seird-ux43cux43eux434ux435ux43bux4
Результаты калибровки стандартной SEIRD-модели]

[[ux43eux446ux435ux43dux43aux430-ux43fux43eux440ux44fux434ux43aux430-ux434ux440ux43eux4
ux43fux440ux43eux438ux437ux432ux43eux434ux43dux43eux439]3.3 Оценка порядка дробной производной]

[[ux444ux43eux440ux43cux430ux43bux44cux43dux43eux435-ux441ux440ux430ux432ux43dux435ux4
ux43cux43eux434ux435ux43bux435ux439]3.4 Формальное сравнение моделей]

[[ux438ux43dux442ux435ux440ux43fux440ux435ux442ux430ux446ux438ux44f-ux3b1$_k-$
$ux43aux430ux43a-ux43cux430ux440ux43aux435ux440ux430-ux43fux43eux43fux443ux43bux44fux$
$ux438ux43cux43cux443ux43dux438ux442ux435ux442ux430]3.5_k]$

7.6 3.1 Описательная характеристика временного ряда и идентификация волн

7.6.1 3.1.1 Общая структура временного ряда

Исходный ряд ежедневной заболеваемости COVID-19 в Пскове охватывает период с 17 марта 2020 года по 30 декабря 2024 года и включает 1750 дней наблюдений. Накопленное число зарегистрированных случаев к концу наблюдаемого периода составило **[N_total]** (из файла `seird_all_waves_trajectories.csv`); суммарное зарегистрированное число летальных исходов — **[D_total]**. Сырой ряд ежедневных приростов содержал 312 пропущенных значений (17,8%), сконцентрированных преимущественно в периоде март–ноябрь 2020 года; все они восстановлены кубической сплайн-интерполяцией накопленного ряда (раздел 2.2.3). После интерполяции и сглаживания гауссовым ядром (σ = 15 дней, раздел 2.2.4) ряд был передан в алгоритм автоматической идентификации волн.

7.6.2 3.1.2 Идентифицированные волны

Алгоритм, основанный на знаке первой производной сглаженного ряда с адаптивным порогом (раздел 2.3), выделил **10 эпидемических волн**. Каждая волна была сопоставлена с доминирующим вариантом SARS-CoV-2 на основании авторского кодировочного словаря штаммов (раздел 2.1.3). Хронологически выделенные волны охватывают смену пяти поколений вариантов: оригинальный уханьский штамм (волны 1–2), Дельта (волна 3), ранние субварианты Омикрон BA.1/BA.2 (волны 4–5), субварианты BA.4/BA.5 (волна 6), поздние Омикрон-субварианты XBB/BQ (волны 7–10).

Таблица 1 — Характеристика идентифицированных волн заболеваемости COVID-19 в Пскове

[]@ >p() * 0.1250 >p() * 0.1250 >p() * 0.1250 >p() * 0.1250 >p() * 0.1250 >p() * 0.1250 >p() * 0.1250 >p() * 0.1250@ Волна

Дата начала

Дата окончания

Штамм

				T, сут	Пик (случ./день)	Σ случаев	Σ смертей
1	[дата]	[дата]	Wuhan	[T]	[peak]	[Σ]	[Σd]
2	[дата]	[дата]	Wuhan/Alpha	[T]	[peak]	[Σ]	[Σd]
3	[дата]	[дата]	Delta	[T]	[peak]	[Σ]	[Σd]
4	[дата]	[дата]	Omicron BA.1	[T]	[peak]	[Σ]	[Σd]
5	[дата]	[дата]	Omicron BA.2	[T]	[peak]	[Σ]	[Σd]
6	[дата]	[дата]	Omicron BA.4/5	[T]	[peak]	[Σ]	[Σd]
7	[дата]	[дата]	Omicron XBB	[T]	[peak]	[Σ]	[Σd]
8	[дата]	[дата]	Omicron XBB.1.5	[T]	[peak]	[Σ]	[Σd]
9	[дата]	[дата]	Omicron EG.5	[T]	[peak]	[Σ]	[Σd]
10	[дата]	[дата]	Omicron JN.1	[T]	[peak]	[Σ]	[Σd]

Примечание. Данные — из файла `seird_all_waves_trajectories.csv`; «Пик» — максимум ряда `daily_interp_smooth`; «Σ случаев» и «Σ смертей» — сумма по дням волны до её конца. *T* — длина волны в сутках.

Длительность волн существенно варьировала: от [T_min] до [T_max] суток (медиана — [T_med] суток). Наиболее интенсивными по абсолютному числу ежедневных случаев были волны 4 и 5, соответствующие периоду доминирования Омикрон BA.1/BA.2; наиболее продолжительной — волна [X]. Суммарное число случаев за первые три волны (оригинальный штамм и Дельта) составляло лишь около [%_1_3]% от совокупного числа случаев по всему периоду наблюдений, что свидетельствует о принципиальном изменении интенсивности регистрации с приходом Омикрон-вариантов.

На рисунке 1 представлена панорама всего ряда с нанесёнными границами волн и указанием доминирующего штамма. На рисунке 2 показаны отдельные профили каждой из 10 волн в линейном и логарифмическом масштабах.

[ПЛЕЙСХОЛДЕР — Рисунок 1]

Рисунок 1 — Ежедневная заболеваемость COVID-19 в Пскове, 2020–2024 гг. Тонкая линия — сырые данные (`daily_interp`), жирная — сглаженный ряд (`daily_interp_smooth`). Вертикальные штриховые линии — границы волн; цветовые полосы — периоды доминирования вариантов.

[ПЛЕЙСХОЛДЕР — Рисунок 2]

Рисунок 2 — Нормированные профили 10 волн (ось *x* — дни от начала волны, ось *y* — число случаев в сутки). Верхняя строка — линейная шкала; нижняя — логарифмическая.

7.6.3 3.1.3 Априорные параметры штаммов

Для каждой волны из файла `covid19_seird_params.csv` были извлечены фиксируемые биологические параметры доминирующего варианта (σ и γ) и априорные значения свободных параметров (β и μ). Таблица 2 суммирует эти значения. Значения σ монотонно

возрастали от волны к волне (от [σ_1] до [σ_{10}] сут$^{-1}$), что соответствует общеизвестному укорочению инкубационного периода при смене Дельта на Омикрон-субварианты [4]. Напротив, параметр μ (суточная смертность в компартменте I) обнаружил устойчивое снижение начиная с волны 4, согласующееся с данными об ослаблении вирулентности Омикрон-субвариантов и накоплении гибридного иммунитета [5].

Таблица 2 — Априорные (фиксированные и стартовые) параметры штаммов по волнам

[]@ >p() * 0.1111 >p() * 0.1111 >p() * 0.1111 >p() * 0.1111 >p() * 0.1111 >p() * 0.1111 >p() * 0.1111 >p() * 0.1111 >p() * 0.1111@ Волна

Штамм

σ, сут$^{-1}$

γ, сут$^{-1}$

β_prior

μ_prior

R_0_prior

T_incub, сут

T_infect, сут

1 Wuhan [σ] [γ] [β] [μ] [R_0] [T] [T]

2 Wuhan/Alpha [σ] [γ] [β] [μ] [R_0] [T] [T]

3 Delta [σ] [γ] [β] [μ] [R_0] [T] [T]

4 Omicron BA.1 [σ] [γ] [β] [μ] [R_0] [T] [T]

5 Omicron BA.2 [σ] [γ] [β] [μ] [R_0] [T] [T]

6 Omicron BA.4/5 [σ] [γ] [β] [μ] [R_0] [T] [T]

7 Omicron XBB [σ] [γ] [β] [μ] [R_0] [T] [T]

8 Omicron XBB.1.5 [σ] [γ] [β] [μ] [R_0] [T] [T]

9 Omicron EG.5 [σ] [γ] [β] [μ] [R_0] [T] [T]

10 Omicron JN.1 [σ] [γ] [β] [μ] [R_0] [T] [T]

Примечание. σ = 1/T_incub, γ = 1/T_infect; β_prior и μ_prior — стартовые значения для оптимизации. R_0_prior = β_prior/γ. Источник: `covid19_seird_params.csv`.

8 3.2 Результаты калибровки стандартной SEIRD-модели

8.0.1 3.2.1 Подобранные параметры

По завершении трёхступенчатой процедуры оптимизации (раздел 2.7) для каждой из 10 волн был получен вектор подобранных параметров целочисленной модели $\hat{\theta}_k^{int} = (\hat{\beta}_k, \hat{\mu}_k, \hat{E}_{0,k}, \hat{I}_{0,k}, \hat{N}_{eff,k}$ Параметры σ и γ оставались фиксированными на значениях из Таблицы 2 на протяжении всей оптимизации. Итоговые значения представлены в Таблице 3.

Таблица 3 — Подобранные параметры целочисленной SEIRD-модели (main7) по волнам

[]@ >p() * 0.0943 >p() * 0.0943 >p() * 0.1132 >p() * 0.0943 >p() * 0.0755 >p() * 0.0755 >p() * 0.0943 >p() * 0.2830 >p() * 0.0755@ Волна

β_fit

R_0_fit

μ_fit

E_0

I_0

N_eff

							N_eff/N_city, %		
							loss		
1	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
2	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
3	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
4	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
5	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
6	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
7	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
8	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
9	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	
10	[β]	[R_0]	[μ]	[E_0]	[I_0]	[N]	[%]	[L]	

Примечание. loss — значение log-MSE по случаям (и по смертям при Σd > 5) в точке оптимума; N_eff/N_city — доля вовлечённой восприимчивой популяции относительно N_city = 200 000. Источник: `seird_all_waves_params.csv`.

8.0.2 3.2.2 Отклонение подобранного R_0 от априорного

Сравнение $\hat{R}_{0,k}^{fit} = \hat{\beta}_k/\gamma_k$ с априорными значениями $R_{0,k}^{prior}$ (Таблица 2) показало устойчивую тенденцию: для всех волн, начиная с волны 4 (Омикрон BA.1), подобранное $\hat{R}_0$ оказалось **ниже** значения, ожидаемого для данного штамма из литературных данных. Это расхождение нарастало по мере смены субвариантов Омикрон и к волнам 7–10 составляло в среднем [ΔΔAIC]% от литературного R_0. Данный результат интерпретируется как проявление накопленного популяционного иммунитета (гибридного, вследствие перенесённой инфекции и вакцинации): снижение эффективного числа воспроизводства относительно «вирусологического» R_0 штамма отражает уменьшение доли подлинно восприимчивых индивидов.

Для волн 1 и 2 подобранный R_0 был, напротив, несколько **выше** априорного, что согласуется с отсутствием коллективного иммунитета в начале пандемии и возможной роли завозных случаев из более высококонтактного региона.

На рисунке 3 показана динамика R_0 prior vs. R_0 fit по волнам для целочисленной модели.

[ПЛЕЙСХОЛДЕР — Рисунок 3]

Рисунок 3 — Сравнение R_0_prior (литературные данные по штамму) и R_0_fit (целочисленная SEIRD, main7) по волнам. По горизонтальной оси — номер волны; маркеры разной формы соответствуют двум источникам R_0.

8.0.3 3.2.3 Динамика эффективной популяции

Подобранные значения эффективной восприимчивой популяции $\hat{N}_{eff,k}$ обнаруживали выраженное уменьшение от ранних волн к поздним. Для волн 1–3 $\hat{N}_{eff}$ составлял [$\%_1$]–[$\%_3$]% от N_{city}, тогда как для волн 7–10 — лишь [$\%_7$]–[$\%_{10}$]%. Монотонный нисходящий